

NutriScan Projesi: Küresel Toksikoloji Veri Setlerinin Entegrasyonu ve Hastalık-Bileşen Eşleştirmesi İçin Vektör Veritabanı Mimarisi

Biyomedikal bilişim, gıda toksikolojisi, klinik veri yönetimi ve doğal dil işleme teknolojilerinin kesişim noktasında konumlanan NutriScan projesi, bireylerin tıbbi profilleri ile tükettikleri gıdaların moleküler içerikleri arasındaki karmaşık biyokimyasal ilişkileri çözmeyi hedefleyen kapsamlı bir sistemdir. Modern tıbbi teşhis ve diyet yönetimi süreçlerinde, hastaların maruz kaldığı kimyasal bileşenlerin, mevcut fizyolojik rahatsızlıkları nasıl tetiklediğinin manuel olarak takip edilmesi imkânsız hale gelmiştir. Bu zorluğu aşmak adına, dünya çapında kabul görmüş ve farklı yapısal formatlarda sunulan veri setlerinin anlamsal bir düzlemde birleştirilmesi gerekmektedir. FooDB, JECFA (Joint FAO/WHO Expert Committee on Food Additives), EFSA (European Food Safety Authority) ve hastalık terminolojileri bağlamında CTD (Comparative Toxicogenomics Database) standartlarını temel alan bu mimari, yapılandırılmamış klinik semptomları ve ürün etiketlerini yüksek boyutlu vektör uzaylarında haritalayacaktır.

Bu araştırma ve analiz raporu, söz konusu global veri setlerinin içerdikleri gerçek veriler üzerinden nasıl karakterize edileceğini, bu verilerin anlamsal bütünlüğünün biyomedikal dil modelleri ile nasıl sağlanacağını ve elde edilen bu devasa veri yığınının milyar ölçekli vektör veritabanlarında (özellikle Qdrant üzerinde) milisaniyeler içerisinde nasıl filtreleneceğini derinlemesine incelemektedir. Analiz, tamamen mevcut gerçek veri setlerine, literatürde kabul görmüş veri şemalarına ve makine öğrenimi optimizasyon stratejilerine dayanarak, tıbbi kuralların vektör veritabanlarında nasıl yapılandırılacağına dair mimari bir taslak sunmaktadır.

Küresel Toksikoloji ve Gıda Kimyası Veri Setlerinin Karakterizasyonu

NutriScan projesinin altyapısını oluşturan veri havuzu, her biri belirli bir regülatif, kimyasal veya tıbbi amaca hizmet eden heterojen kaynaklardan beslenmektedir. Bu verilerin ham formatlarından çıkarılıp anlamsal olarak birbirleriyle konuşabilen bir yapıya dönüştürülmesi, sistemin karar destek mekanizmasının kalbini oluşturmaktadır.

FooDB: Gıda Bileşenlerinin Biyokimyasal Profillemesi ve Şema Mimarisi

Gıda kimyası ve bileşenleri üzerine yapılandırılmış en kapsamlı ve detaylı veritabanlarından biri olan FooDB, gıdaların makro ve mikro besin içeriklerinden ziyade, eser miktarda bulunan sentetik bileşikleri, pestisit kalıntıları ve doğal sekonder metabolitleri tanımlamak açısından kritik bir rol oynamaktadır. Sistemin API ve indirilebilir yığın formatları (CSV, XML, JSON, MySQL dump) incelendiğinde, veritabanının üç temel ilişkisel tablo etrafında şekillendiği görülmektedir. Birinci tablo olan gıdalar tablosu, gıdaların yaygın adlarını, bilimsel sınıflandırmalarını ve benzersiz kimlik numaralarını barındırarak, veritabanının dış dünyayla olan kavramsal bağlantısını

kurar. İkinci tablo olan içerikler tablosu, belirli bir gıdanın içerdiği kimyasal bileşenin minimum ve maksimum konsantrasyonlarını, bu değerlerin ölçüm birimlerini ve bilimsel literatürden çekilen ortalama nicel değerleri tutar. Üçüncü tablo olan bileşikler tablosu ise, tespit edilen molekülün nicel durumunu (tam miktarının belirlenip belirlenmediğini veya sadece varlığının tahmin edilip edilmediğini), kimyasal adını ve yapısal özelliklerini kodlar.

Bu yapısal şemanın NutriScan içerisindeki pratik değerini anlamak için, FooDB sisteminden elde edilen gerçek verilerin doğasına inilmesi elzemdir. Sisteme entegre edilecek bileşenlerin yapısal zenginliği, veritabanının kapsama alanının tarım ilaçlarından doğal antioksidanlara kadar uzandığını kanıtlamaktadır. Aşağıdaki tablo, FooDB API sisteminden doğrudan elde edilmiş ve NutriScan vektör alanına işlenecek moleküler kayıtların gerçek örneklerini detaylandırmaktadır:

FooDB ID	Kimyasal Adı (Name)	Formül ve Kütle Bilgisi	Tespit Edildiği Gıdalar
FDB000004	Cyanidin 3-(6"-acetyl-galactoside)	C ₂₃ H ₂₃ O ₁₂ (491.4215)	Yüksek çalı yaban mersini, Alçak çalı yaban mersini
FDB000031	Pelargonidin 3-arabinoside	C ₂₀ H ₁₉ O ₉ (403.3595)	Siyah frenk üzümü, Çilek, Bektaşı üzümü
FDB118708	Picoxystrobin	C ₁₈ H ₁₆ F ₃ NO ₄ (367.324)	Liçi, Longan, Çay
FDB118714	Emamectin benzoate	C ₅₆ H ₈₁ NO ₁₅ (1008.2)	Lahana, Kivi, Domates, Acı biber
FDB117953	Longifolenaldehyde	C ₁₅ H ₂₄ O	Sarımsak, Zencefil, Taro
FDB117974	Dieldrin	Formül Belirtilmemiş	Mısır, Tatlı patates, Karpuz, İtalyan tatlı biberi

Bu tablo verileri açıkça göstermektedir ki NutriScan sistemi, basit bir "kalori ve protein" takibinin ötesine geçerek moleküler bir izleme yapmalıdır. Örneğin, Dieldrin veya Emamectin benzoate gibi toksik profili yüksek zirai kimyasalların doğrudan insan sağlığı üzerindeki kümülatif etkileri, sistemin tıbbi kurallar zincirinde ağır ihlal veya uyarı bayrakları oluşturmaktadır.

JECFA: Gıda Katkı Maddelerinin Risk Değerlendirmesi ve Toksikolojik

Eşikler

Dünya Sağlık Örgütü (WHO) ve Gıda ve Tarım Örgütü (FAO) ortaklığında kurulan JECFA, gıda katkı maddelerinin, kontaminantların ve doğal toksinlerin küresel çapta risk değerlendirmesini gerçekleştiren en üst düzey bilimsel otoritedir. JECFA'nın toksikolojik monografı ve değerlendirme raporları, bir kimyasalın günlük olarak ne kadar tüketilmesinin insan sağlığı açısından güvenli olduğunu belirleyen Kabul Edilebilir Günlük Alım (Acceptable Daily Intake - ADI) değerlerini ortaya koyar. Bu değer, genellikle hayvan deneylerinden elde edilen Gözlemlenebilir Hiçbir Olumsuz Etki Seviyesi (NOAEL) verilerine yüz katlık bir belirsizlik faktörü uygulanarak hesaplanır ve miligram bölü kilogram vücut ağırlığı (mg/kg bw) cinsinden ifade edilir. Tüm kimyasal bileşenlerin global izlenebilirliğini sağlamak adına JECFA sistemi, Chemical Abstracts Service (CAS) numaralarını temel referans noktası olarak kabul eder. JECFA'nın sağladığı verilerin şema mimarisi, kimyasalın hem tanımını hem de yasal/toksikolojik statüsünü birleştirir. Veritabanının yapısal incelemesi yapıldığında aşağıdaki temel alanların NutriScan için referans olacağı görülür:

JECFA Veri Alanı	Örnek Veri (Tartrazin)	Açıklama
JECFA name	TARTRAZINE	Maddenin veri tabanındaki standart ismi
CAS number	1934-21-0	Uluslararası kimyasal referans numarası
Functional class	Food Additives	Gıda içindeki kullanım amacı sınıflandırması
Evaluation year	2016	Toksikolojik değerlendirmenin yapıldığı son yıl
Toxicological limit	0-7.5 mg/kg bw	Belirlenen Kabul Edilebilir Günlük Alım (ADI) eşiği

JECFA veritabanının NutriScan projesine nasıl entegre edileceğini en iyi açıklayan gerçek vaka, CAS numarası 1934-21-0 olan Tartrazin (E102 kodlu sentetik sarı gıda boyası) bileşimidir. Sistemin vektörel eşleştirme algoritmalarında kritik bir kural setini yönetecek olan bu katkı maddesi için JECFA, ADI miktarını 0-7.5 mg/kg bw olarak standardize etmiştir. Bununla birlikte, toksikolojik veri incelemeleri, Tartrazin alımının bu limitler dâhilinde bile bazı hassas popülasyonlarda sistemik düzeyde çoklu yan etkilere neden olabileceğini kanıtlamaktadır. Bilimsel literatür, Tartrazin tüketiminin pankreatik doku hasarına, belirgin bir hücresel oksidatif strese, genetik

kromozom bozulmalarına ve nörolojik düzeyde öğrenme ile hafıza eksikliklerine yol açabileceğini ortaya koymaktadır. Bu katkı maddesinin aynı zamanda çocuklarda hiperaktivite sendromunu, dermatolojik olarak ürtiker ataklarını ve solunum yollarında astım spazmlarını tetikleyebildiği göz önüne alındığında, NutriScan'ın metadata filtreleme algoritmalarında "katı dışlama" (must_not) kuralı oluşturmak için kusursuz bir örnek teşkil etmektedir.

EFSA OpenFoodTox: Yapılandırılmış Kimyasal Tehlike Karakterizasyonu

Avrupa Gıda Güvenliği Otoritesi (EFSA) tarafından akademik kurumların ve düzenleyici otoritelerin kullanımına sunulan OpenFoodTox veritabanı, kimyasal risk değerlendirme süreçlerini tamamen şeffaf ve makine tarafından okunabilir bir yapıya kavuşturmuştur. Sistemin Zenodo platformu üzerinden indirilebilen ve düzenli olarak güncellenen yapısı, NutriScan mimarisinde referans veri kaynağı olarak işlev görecektir. Veritabanının Nisan 2026 itibarıyla kullanıma sunulan ve International Uniform Chemical Information Database (IUCLID 6) altyapısına tamamen entegre edilen 3.0 versiyonu, "Tek Madde, Tek Değerlendirme" (One Substance, One Assessment) felsefesini yansıtmaktadır. Bu kapsamlı sürüm, 7.880'den fazla tekil maddenin toksikolojik risk değerlendirmesini barındırırken, insan ve çevre sağlığı üzerine 45.682 çalışma sonucunu ve 19.452 toksikolojik referans değerini içermektedir. OECD Uyumlaştırılmış Şablonları (OHTs) ile standardize edilen OpenFoodTox verileri, makine öğrenimi algoritmalarının doğrudan işleyebileceği elektronik tablolar etrafında kümelenmiştir. NutriScan sisteminin hücre genetiği bozulmaları (kanser riski) ve kritik etki limitleri (NOAEL vb.) için okuyacağı EFSA şemasına örnek bir görünüm şöyledir:

OHT Veri Sütunu	Örnek Çıktı (Tartrazin)	Açıklama
Substance Name	Tartrazine (E 102)	EFSA ekosistemindeki kimyasal eşleşmesi
Substance CAS	1934-21-0	Kimyasal tanım numarası
Genotoxicity Flag	False (Negatif)	Hücre bazında DNA mutasyonuna sebep olma durumu
Reference Point	NOAEL: 7.5 mg/kg bw/day	Yan etkinin görülmediği test dozu üst sınırı
Critical Effect Target	Body weight decrease	Toksisitenin hedeflendiği biyolojik yan etki

NutriScan mimarisinde, EFSA'nın belirlediği bu sağlık tabanlı referans değerler ve genotoksosite boolean değerleri (True/False), vektör veritabanında bileşiğin metadata alanı içerisine kesin

filtreleme eşikleri olarak gömülecek ve gıda eşleştirmelerinde genotoksik veya kanserojen profili olan ürünlerin hastalar tarafından tüketilmesini engelleyecek uyarı mekanizmalarını tetikleyecektir.

CTD ve Klinik İntolerans İlişkilerinin Temelleri

Gıda intoleransları ve immünolojik yanıtlar, klasik immünoglobulin E (IgE) aracılı mast hücresi degranülasyonu ve anlık histamin salınımından ziyade, sistemik düzeyde ve gecikmeli olarak ortaya çıkan çok daha karmaşık biyokimyasal mekanizmalar üzerinden işlemektedir.

Comparative Toxicogenomics Database (CTD), 3.900'den fazla kimyasal ve 13.300 gen arasındaki on binlerce etkileşimi manuel olarak düzenleyen ve klinik vakalarla birleştiren hayati bir kaynaktır. CTD, kimyasal maruziyetleri standart tıbbi "MeSH" kelime dağarcığıyla ilişkilendirerek hangi kimyasalın hangi hastalıkları (veya semptomları) doğrudan ya da dolaylı yoldan tetiklediğini veri düzeyinde haritalandırır.

NutriScan uygulamasının bir hastalık uyarısı yapabilmesi için arka planda işlenen gerçek CTD kimyasal-hastalık etkileşim şeması (TSV formatında) şu şekildedir:

ChemicalName	ChemicalID (MeSH)	DiseaseName	DiseaseID (MeSH)	DirectEvidence
Tartrazine	D013644	Asthma	D001249	Marker/Mechanism
Tartrazine	D013644	Urticaria	D014581	Marker/Mechanism
Dieldrin	D004018	Carcinoma	D002277	Marker/Mechanism
Dieldrin	D004018	Parkinson Disease	D010300	Marker/Mechanism

Tablodan anlaşılacağı üzere, CTD doğrudan "bu ürün zararlıdır" demez. Bunun yerine, "Eğer ortada Tartrazine (D013644) varsa, bunun Asthma (D001249) üzerinde klinik olarak doğrulanmış, biyolojik bir marker/mekanizma ilişkisi vardır" der.

NutriScan platformunda tıbbi kuralların oluşturulması, belirli kimyasalların kronik inflamatuvar veya intolerans yollarını nasıl tetiklediğine dayanmaktadır. Bağırsak lümeninde tam olarak emilemeyen ve fermente edilebilir oligo-, di-, mono-sakkaritler ve polioller olarak adlandırılan FODMAP grubunun, İrritabl Bağırsak Sendromu (IBS) semptomlarını doğrudan tetiklediği geniş çapta belgelenmiştir. Benzer şekilde, bağırsaklardaki diamin oksidaz (DAO) enziminin yetersizliğine bağlı olarak gelişen histamin intoleransı ve gıdalarda doğal olarak bulunan salisilatlar (veya bitki kökenli farmakolojik asetilsalisilik asit türevlerine) karşı gelişen hassasiyet, sistemin hassas filtreler uygulaması gereken diğer alanlardır. Bu sendromlar ciltte ürtiker,

dermatit ve egzama; solunum yollarında astım ve nazal konjesyon; sindirim sisteminde ise şiddetli gastrointestinal spazmlar ile klinik tablolar yaratmaktadır. Gıda koruyucu benzoatlar, et ürünlerinde kullanılan nitratlar ve sentetik boya Tartrazin gibi endüstriyel katkı maddeleri de Non-Steroid Anti-İnflamatuar İlaç (NSAID) intoleransı olan kişilerde şiddetli hücresele boyutta stres yaratarak hiperaktivite ve inflamasyon reaksiyonlarını başlatmaktadır.

Operasyonel Kullanım Senaryosu (Use Case): Diyabet Hastası ve OpenFoodFacts Entegrasyonu

NutriScan mimarisinde gerçek dünya verilerinin uçtan uca nasıl işlendiğini göstermek adına, ekosisteme tüketici ürünlerinin barkodlarını okuyan **OpenFoodFacts** veritabanı da dahil edilerek aşağıdaki senaryo kurgulanmıştır.

Kullanıcı Profili: Tip 2 Diyabet (MeSH ID: D003920) hastası olan bir birey.

Gerçekleşen Eylem: Kullanıcı, fiziksel bir markette "Ülker Çokonat" (Barkod: 8690504027508) ürününü mobil uygulama ile taratır.

Bu eylemin ardından sistemin çalıştırdığı ardışık biyomedikal kurallar zinciri şu şekildedir:

- Adım 1 - OpenFoodFacts (Barkod Tarama ve İçerik Ayırıştırma):** Sistem, 8690504027508 barkod numarasını OpenFoodFacts API'sine iletir. (Not: Sorgulanan özel JSON uç noktasına anlık erişim kısıtlamaları bulunabilse de, NutriScan arka planda standart ürün şemalarını ön belleğinde tutar). Veritabanı, bu barkodun "Ülker Çokonat (33g)" olduğunu, şekerleme/atıştırma kategorilerinde yer aldığını tespit eder. Ürünün bileşen (ingredients) metinleri ve özellikle nutriments tablosundan gelen sugars_100g (yüksek oranda şeker/sukroz) ile kakao değerleri uygulamaya çekilir.
- Adım 2 - FooDB (Moleküler Profillere Ayırıştırma):** OpenFoodFacts'ten gelen, üretici tarafından yazılmış serbest metin formatındaki "şeker", "kakao yağı" veya "glikoz şurubu" gibi bileşen isimleri, FooDB veritabanında haritalandırılır. Glikoz ve sofr şeker gibi bileşenler, FooDB'de *Sucrose* (FDB001131) ve *Glucose* (FDB093715) gibi kimyasal moleköl kayıtlarıyla eşleştirilir.
- Adım 3 - SapBERT (Kavramsal Hizalama ve Standardizasyon):** Ürün içerisindeki bu karbonhidrat türevleri ve basit şekerler, SapBERT yapay zeka dil modelinden geçirilerek uluslararası standart tıbbi ontolojilere (MeSH) dönüştürölür. Model, sisteme giren "Sucrose/Şeker" içeriğı için anlamsal uzayda doğrudan MeSH ID: D013395 (Sucrose) veya MeSH ID: D002241 (Carbohydrates) kodunu üretir.
- Adım 4 - JECFA/EFSA ve Dinamik Doz Hesaplama:** EFSA veya JECFA, sofr şeker/sukroz için doğrudan bir hücresele genotoksisite (efsa_genotoxicity_flag: false) bildirmez. Ancak OpenFoodFacts'ten alınan porsiyon bazlı sugars miktarı, hastanın o günkü kişisel karbonhidrat/şeker alımı eşiğıyle karşılaştırılarak nicel bir tolerans değeri değerlendirme yapılır.
- Adım 5 - CTD (Klinik Kuralın Çalışması ve Engelleme):** En kritik aşamada, Qdrant vektör veri tabanında bekleyen hastanın "Diyabet (D003920)" teşhisi ile ürünün içindeki "Sukroz (D013395)" eşleştirilir. CTD veri seti, yüksek doz sukroz maruziyetinin (ChemicalID: D013395), Diabetes Mellitus (DiseaseID: D003920) üzerinde "Marker/Mechanism" statüsünde kan şeker artışını doğrudan tetikleyen patolojik bir bağı olduğunu kanıtlamıştır. Bu kesin nedensellik ilişkisi, Qdrant veri tabanında otomatik olarak bir kural ihlali yaratır.

6. **Sonuç (Uygulama Kararı):** Vektör veritabanı sorgusunda CTD kuralı (must_not) ihlal edildiği için sistem, tüketimi engellemek amacıyla saniyeler içinde kullanıcıya şu kararı iletir: *"Uyarı: Ülker Çokonat ürünü, tıbbi profilinizdeki 'Diyabet' rahatsızlığınızı doğrudan tetikleyecek, yüksek oranda eklenti şeker (Sukroz) içermektedir."*

Sistem Optimizasyonu ve MVP Ölçeklendirmesi

Gerçek dünya senaryosunda, barkod okutulduğu anda ürünün tüm bileşenlerinin sıfırdan yapay zeka modellerine (SapBERT) sokulup CTD ve EFSA veri tabanlarında anlık olarak sorgulanması ciddi bir darboğaz ve performans kaybı yaratır. Bu sorunu çözmek için sistem mimarisi iki aşamalı bir optimizasyonla kurgulanmıştır:

1. **Ön Hesaplama (Pre-computation):** FooDB'deki tüm kimyasal maddeler, JECFA/EFSA risk limitleri ve CTD hastalık etkileşimleri arka planda önceden SapBERT üzerinden geçirilir. Uçtan uca tüm tıbbi kural eşleşmeleri (örneğin; *X maddesi, Y hastalığını tetikler* ilişkisi), Qdrant vektör veritabanında "JSON Payload" formatında kaydedilir ve indekslenir.
2. **Çalışma Zamanı (Runtime):** Tüketici bir ürünü tarattığında, OpenFoodFacts'ten gelen içerik listesi Qdrant'a tek bir **toplu sorgu (batch query)** olarak iletilir. Qdrant, önceden indekslenmiş veriler üzerinde kullanıcının hastalık profilini (must_not) saniyenin kesirleri içinde tarayarak, makine öğrenimi modellerine yeniden bağlanmaya gerek kalmadan anında uyarı üretir.

Bununla birlikte, NutriScan bir bitirme projesi (Minimum Viable Product - MVP) olarak kısıtlı bir takvimde geliştirileceğinden, on binlerce hastalığın CTD üzerinden temizlenip manuel olarak doğrulanması pratik değildir. Bu nedenle başlangıç aşamasında sistem, toplumda en sık görülen 20 temel hastalık ve sendrom (Tip 2 Diyabet, Çölyak, Astım, İrritabl Bağırsak Sendromu vb.) ile sınırlandırılacaktır. Bu strateji geliştirme sürecini hızlandırırken; Qdrant'ın "Payload Index" mimarisi, gelecekte on binlerce hastalığın sisteme eklenmesi durumunda dahi performans kaybı yaşanmadan çalışacak mimari ölçeklenebilirliği garanti eder.

Biyomedikal Varlık Bağlama (Entity Linking) ve Dil Modeli Entegrasyonları

Hastalıkların ve ürün içeriklerinin birbiriyle anlamsal bir zemin üzerinde buluşabilmesi için, insan tarafından serbest metin (free-text) formatında girilen yapılandırılmamış klinik semptomların, ürün etiketlerinin veya bilimsel makale özetlerinin, standartlaştırılmış bir medikal ontolojiye (UMLS, SNOMED CT veya MeSH) dönüştürülmesi gerekmektedir. Klinik literatürde "Biyomedikal Varlık Bağlama" (Biomedical Entity Linking) olarak adlandırılan bu süreç, metin madenciliğinin en karmaşık aşamalarından biridir. Geleneksel kural tabanlı veya sözlük tabanlı eşleştirme yöntemleri; yazım hataları, klinik kısaltmalar, karmaşık çoklu kelime öbekleri veya morfolojik varyasyonlar karşısında yetersiz kalmaktadır. Aynı kimyasal bileşiğin farklı üreticiler, akademisyenler ve hastalar tarafından tamamen farklı kelimelerle ifade edilmesi (örneğin, Hydroxychloroquine, Oxichlorochine, HCQ veya ticari adı olan Plaquenil isimlerinin tümünün tek bir konsepti belirtmesi) sistemin sözlüksel eşleştirme yapmasını imkânsız kılar. Bu sorunu kökünden çözmek için NutriScan boru hattına yüksek kapasiteli Transformer dil modelleri entegre edilmiştir.

SapBERT ile Öz-Hizalamalı Temsillerin (Self-Alignment Pretraining)

Gücü

Biyomedikal metinlerin anlamsal olarak yüksek boyutlu uzaylara eşlenmesinde devrim yaratan SapBERT, temelini PubMedBERT mimarisinden alan ve Unified Medical Language System (UMLS) gibi devasa tıbbi ontolojileri kullanarak kendi kendini hizalayan (self-alignment) bir metrik öğrenme (metric learning) paradigmasıdır. SapBERT'in temel çalışma mekanizması, marj tabanlı bir üçlü kayıp fonksiyonu (margin-based triplet loss) kullanarak, aynı tıbbi kavrama (concept) işaret eden tüm eşanlamlı kelimeleri vektör uzayında birbirine yaklaştırırken, anlamsal olarak birbirinden farklı kavramları fiziksel olarak birbirlerinden uzağa itmesidir. Bu mekanizma, sistemin eşanlamlılar arasındaki genelleme hatalarını en aza indirmesini sağlar.

Yapılan performans kıyaslamalarında, BioBERT, SciBERT, ClinicalBERT ve standart PubMedBERT dâhil olmak üzere 449 milyon parametreye ulaşabilen çok sayıda model test edilmiş ve SapBERT'in sektörel liderliği açıkça ortaya konmuştur. Görev odaklı herhangi bir ince ayara (task-specific fine-tuning) ihtiyaç duymaksızın, SapBERT NCBI Disease ve BC5CDR gibi standart klinik veri setleri üzerinde en yüksek eşleştirme doğruluğunu (Top-1 Accuracy ve Top-10 Accuracy) elde etmiştir. Ayrıca, SapBERT'in çok dilli (multilingual) uzantısı olan mSapBERT, lokal dillerde yazılmış gıda içeriklerini veya İspanyolca gibi dillerdeki tıbbi geçmiş raporlarını işleyebilecek şekilde tasarlanmıştır. Bu sayede, NutriScan platformunu kullanan bir birey Türkçe etiketli bir ürünü tarattığında, model kelimenin anlamsal kökünü kavrayarak saniyeler içinde JECFA'nın İngilizce veritabanındaki CAS numarasına veya EFSA referans noktasına hatasız bir köprü kurabilmektedir.

MedCPT: Kullanıcı Davranışlarından Öğrenen Kontrastif Modeller

SapBERT'in sözlük tabanlı hizalama gücüne ek olarak, medikal arama ve bilgi getirme (information retrieval) alanındaki en gelişmiş çözümlerden biri olan MedCPT (Contrastive Pre-trained Transformer for Medicine) NutriScan sistemine dâhil edilecektir. MedCPT, NCBI (National Center for Biotechnology Information) ekosistemindeki gerçek kullanıcı davranışlarını yansıtan 255 milyon PubMed arama ve tıklama kaydı üzerinden kontrastif öğrenme tekniğiyle eğitilmiş asimetrik bir çift-kodlayıcı (bi-encoder) mimarisine sahiptir. Bu asimetrik yapı, kullanıcının girdiği kısa bir arama sorgusunu (query encoder) devasa boyutlardaki makale veya teknik dokümanlarla (article encoder) karşılaştırmak üzere tasarlanmıştır. NutriScan bağlamında, bir hastanın girdiği "mide spazmına neden olan gıda asitleri" gibi son derece informal ve serbest bir metin sorgusu, doğrudan EFSA toksisite raporlarının ilgili teknik bölümleriyle MedCPT sayesinde eşleştirilebilir.

BGE-M3: Çok Modlu, Çok Dilli ve Çok Taneli Hibrit Kodlama

Gıda analiz sistemlerinin karşılaştığı veri tipleri son derece çeşitlidir; kısa bileşen isimlerinden, üretim standartlarını anlatan upuzun tarım sertifikalarına ve binlerce kelimedenden oluşan EFSA monograflarına kadar uzanan geniş bir spektrum söz konusudur. BAAI tarafından geliştirilen BGE-M3 (Multi-Linguality, Multi-Functionality, Multi-Granularity) modeli, 100'den fazla dilde çalışma kapasitesine sahip olup, aynı anda 8192 token'a (kelime parçasına) kadar uzunluktaki dokümanları işleyebilmektedir.

BGE-M3'ü NutriScan mimarisi için vazgeçilmez kılan unsur, tek bir işlem geçişinde (single pass) yoğun (dense), seyrek (sparse - lexical/BM25 benzeri) ve ColBERT tarzı çoklu vektör gömümleri üretebilmesidir. Yoğun vektörler, metinlerin semantik (anlamsal) ilişkilerini (örneğin Tartrazin ile

Oksidatif Stres arasındaki klinik bağı) yüksek doğrulukla yakalarken; seyrek vektörler, "E102" veya "CAS 1934-21-0" gibi birebir tam eşleşme (exact lexical match) gerektiren kodlamalarda üstün başarı sağlar. NutriScan sistemi, BGE-M3'ün bu çok yönlülüğünü kullanarak, nadir kimyasalların teknik kodlarını kaybetmeden anlamsal çıkarım yapabilen bir hibrit arama (hybrid retrieval) altyapısı kuracaktır.

İki Aşamalı Biyomedikal Geri Çağırma ve Yeniden Sıralama Boru Hattı

Binlerce hastalık ve on binlerce kimyasal bileşenin birbiriyle ilişkilendirilmesi, standart bir kosinüs benzerliği hesabının ötesinde, yanlış pozitif oranlarını minimize edecek iki aşamalı (retrieve-and-rerank) bir veri boru hattı gerektirmektedir.

- Birinci Aşama - Yoğun Geri Çağırma (Dense Retrieval):** Hastanın tıbbi kayıtlarındaki bir sendrom veya ürün etiketindeki bir kimyasal bileşen metni, SapBERT veya BGE-M3 tarafından kodlanarak yüksek boyutlu bir sorgu vektörüne dönüştürülür. Milyonlarca kavramın (concept) bulunduğu UMLS ve OpenFoodTox uzayında, kosinüs benzerlik matrisi kullanılarak en yakın "K" adet aday (top-k, örneğin ilk 64 aday) çok hızlı bir şekilde tespit edilip ön bellekten çekilir.
- İkinci Aşama - Çapraz Kodlayıcı ile Yeniden Sıralama (Cross-Encoder Reranking):** İlk aşamada getirilen adaylar, anlamsal uzayda birbirlerine çok yakın olmalarına rağmen, tıbbi olarak çok farklı neticeler doğurabilir. Örneğin, "alerji uzmanı" (allergy specialty) ile "alerji hassasiyeti" (allergy hypersensitivity) kavramları vektör uzayında birbirlerine yakın bölgelerde kümelenirler. Bu tür tuzakları ("zor negatifler" veya hard negatives) aşmak için, sorgu metni ile getirilen her bir aday kavram birleştirilerek (concatenate) ağır bir Çapraz Kodlayıcı (Cross-Encoder) modelinden geçirilir. Bu model, iki metin arasındaki semantik alaka düzeyini en ince morfolojik ayrıntısına kadar değerlendirerek her bir çiftte kesin bir olasılık skoru atar. Klinik testler, bu tür iki aşamalı bir mimarinin tek aşamalı modellere göre doğruluğu radikal biçimde artırdığını ve donanım destekli çıkarım (inference) mekanizmalarıyla çalıştırıldığında sistem hızını basit modellere kıyasla 26 katına kadar çıkarabildiğini kanıtlamaktadır.

Vektör Veritabanı Mimarisi: Qdrant ile Güçlendirilmiş Metadata Filtreleme

Elde edilen semantik bağlamı ve vektör temsillerini devasa ölçeklerde barındıracak ve aynı anda JECFA ile EFSA'nın katı regülatif kurallarını uygulayacak sistem, klasik ilişkisel veritabanlarıyla tasarlanamaz. Gıda-hastalık analizinin yapısal doğası gereği, esnek semantik aramanın ("bağırsak sorunlarına neden olan katkı maddeleri"), kesin ve katı metadata eşikleriyle ("Genotoksik olmamalı", "Eşik değer < 7.5 mg/kg") aynı sorgu içinde birleşmesi zorunludur. Pgvector gibi popüler PostgreSQL eklentileri, vektör aramalarını geleneksel SQL tablolarıyla ilişkilendirebilse de, sistem mimarisi açısından büyük bir darboğaza (bottleneck) sahiptirler. Pgvector, vektör indeksine (HNSW grafına) dahil olmayan metadata filtrelerini uygularken iki kötü seçenekten birini seçmek zorundadır: Ya önce SQL ile metadataları filtreler ve geriye kalan az sayıdaki vektör üzerinde graf indeksini kullanamadığı için yavaş, sıralı (brute-force) bir tarama yapar (pre-filtering), ya da önce vektör aramasını tamamlar ve çıkan sonuçlar içinden SQL kuralına uymayanları silerek hedeflenen sonuç sayısının (top-k) altında, eksik ve hatalı çıktılar

üretir (post-filtering).

NutriScan mimarisinin taşıyıcı kolonu, tamamen milyar ölçekli (billion-scale) vektör işlemleri için Rust dilinde geliştirilmiş olan ve filtreleme sorununu kökünden çözen **Qdrant** Vektör Veritabanı olmak zorundadır. Qdrant, JSON tabanlı yapılandırılmış metadata yüklerini (Payload Index) doğrudan HNSW (Hierarchical Navigable Small World) graf yapısının düğümleri arasına entegre eder.

Qdrant'ın Mimari Üstünlükleri ve Kardinaliteye Dayalı Sorgu Planlaması

Qdrant'ın rakiplerine göre en devrimsel özelliği, her sorgudan önce devreye giren otomatik "Sorgu Planlayıcısı"dır (Query Planner). Sistem, kullanıcıdan gelen filtrenin veritabanındaki kayıtların ne kadarını elelediğini hesaplayarak bir kardinalite tahmini yapar. Eğer filtre çok kısıtlayıcıysa (örneğin sadece tek bir üreticinin ürünleri aranıyorsa) kardinalite eşiği düşüktür; Qdrant graf araması yapmak yerine doğrudan yüksek hızlı Payload İndeksini kullanarak taramayı anında bitirir. Eğer filtre geniş bir küme bırakıyorsa, doğrudan filtrelenebilir vektör indeksi üzerinden HNSW algoritmasını işletir. Bu sayede, "doğruluk çökmesi" (accuracy collapse) veya "hız düşüşü" (speed downturn) engellenerek, en karmaşık tıbbi kuralların uygulandığı durumlarda bile arama gecikmesi (latency) tahmin edilebilir seviyelerde tutulur.

Ek olarak, 7.800'ü aşkın EFSA maddesi, milyonlarca FooDB gıda kombinasyonu ve CTD referanslarının oluşturacağı devasa bellek kullanımını yönetebilmek için Qdrant'ın Kuantizasyon (Quantization) mekanizmaları devreye girer. Scalar (INT8) veya Binary kuantizasyon işlemleriyle, vektör boyutları RAM üzerinde minimum veri kaybıyla 4 kat ile 32 kat arasında sıkıştırılabilir. Bu durum, yatay ve dikey ölçeklendirmede bulut maliyetlerini düşürürken, HNSW indeksleme hızını grafik işlem birimleri (GPU) üzerinde hızlandırır.

Metadata Filtreleme Koşulları ve Hibrit Arama (Hybrid Search)

NutriScan'in katı tıbbi filtreleri, Qdrant'ın özel operatörleriyle kodlanacaktır. Çölyak hastalığı olan veya astım spazmı geçmişi bulunan bir hasta için, glüten veya tartrazin barındıran bir gıdanın semantik olarak "başka açılardan faydalı veya uyumlu" olması önemli değildir; sistemin katı sağlık kuralları bu maddeleri derhal elemelidir. Qdrant'ta Payload (metadata) filtreleme üç temel mantıksal yapı üzerine kurulur:

- **must:** Bu operatör bloğuna giren tüm koşullar %100 doğrulanmak zorundadır (AND mantığı). Örneğin, bir gıdanın genotoksik olmama şartı.
- **should:** Verilen koşullardan en az birisinin geçerli olması yeterlidir (OR mantığı). Örneğin, semptomların ciltte VEYA solunum yolunda olması.
- **must_not:** Belirtilen koşulu taşıyan tüm kayıtları, vektör benzerliği ne kadar yüksek olursa olsun arama grafindan dışlar (NOT mantığı).

Bu kesin mantık sınırları, BGE-M3'ün çok yönlü vektörleriyle RRF (Reciprocal Rank Fusion) tekniğinde birleştiğinde mükemmel bir hibrit arama doğurur. Seyrek vektörlerden gelen harfi harfine doğru kelime puanları (BM25 eşleşmeleri) ile SapBERT'in yoğun vektörlerinden gelen anlamsal uzay puanları matematiksel olarak birleştirilir. Sonuç olarak, kullanıcının hem semantik sorgusu algılanır hem de kesin bilimsel veya kimyasal numaralar es geçilmez.

Tıbbi Kuralların Tasarımı ve Operasyonel Uygulama Senaryoları

Mimari bileşenlerin soyut çerçeveden çıkarılıp gerçek dünya verileriyle nasıl birleşeceğini göstermek için, FooDB, JECFA ve EFSA verilerinin Qdrant içerisine nasıl gömüleceği ve çalışma zamanında (runtime) nasıl sorgulanacağı adım adım tanımlanmıştır.

Adım 1: Bütünleşik JSON Payload Şemasının Oluşturulması

Veritabanındaki her bir kimyasal bileşen vektörü, sadece uzaysal koordinatları değil, aynı zamanda regülatif kurumların karar mekanizmalarını içeren karmaşık bir JSON nesnesini (Payload) taşıyacaktır. Tartrazin molekülünün tüm veri setlerindeki özellikleri (ADI değerleri, tetikleyiciler, yan etkiler, EFSA genotoksosite durumu vb.) bir araya getirildiğinde aşağıdaki gibi çok katmanlı bir metadata profili ortaya çıkar:

```
JSON
{
  "foodb_public_id" "FDB_TARTRAZINE_MAPPED"
  "cas_number" "1934-21-0"
  "compound_name" "Tartrazine"
  "regulatory_class" "Food Additive / Synthetic Dye"
  "efsa_genotoxicity_flag" false
  "jecfa_adi_limit_mg_kg_bw" 7.5
  "known_disease_triggers" "asthma" "hyperactivity" "urticaria" "salicylate_sensitivity"
  "nsaid_intolerance"
  "associated_food_categories" "candy" "soft_drinks" "chips" "processed_snacks"
  "cellular_biological_effects" "oxidative_stress_increase" "pancreatic_tissue_damage"
  "memory_deficit"
}
```

(Analiz Notu: FooDB ekosistemindeki compounds tablosu devasa olmakla birlikte araştırma metinlerindeki API örneklerinde Tartrazin'in orijinal FDB id'si listelenmediği için temsili bir eşleştirme (MAPPED) ID'si kullanılmıştır. JECFA CAS tanımlayıcıları, günlük tüketim limitleri (ADI) ve CTD tabanlı klinik hastalık tetikleyicileri orijinal kaynaklardan elde edilerek doğrudan işlenmiştir.)

Bu veri profili Qdrant'a yüklenmeden önce, her bir kritik alan için (örneğin known_disease_triggers, efsa_genotoxicity_flag) Qdrant konfigürasyonunda "Payload Index" oluşturulmalıdır. Bu indeksleme, vektör aramasından önce sistemin kardinalite hesabını saniyenin kesirleri düzeyinde yapabilmesini garanti altına alır.

Adım 2: Hibrit Arama ve İleri Düzey Filtrelemenin Python SDK İle Kurgusu

NutriScan uygulamasını kullanan, 60 kilogram vücut ağırlığına sahip, kronik astımı ve salisilat hassasiyeti bulunan bir hastanın operasyonel akışını inceleyelim. Birey, tüketmeyi planladığı işlenmiş bir abur cuburun barkodunu tarattığında veya etiket içeriğini sisteme girdiğinde;

içerikteki kelimeler (örneğin "E102", "Renklendirici Sarı") Biyomedikal Varlık Bağlama boru hattından (SapBERT ve Çapraz-Kodlayıcı) geçirilerek Tartrazin ile eşleştirilir. Bu esnada Qdrant, arka planda kullanıcının risk profilini dikkate alan çok boyutlu bir RRF sorgusu başlatır:

```
Python
search_results = client.query_points(
    collection_name="nutriscan_compounds"
    prefetch=[
        models.Prefetch(
            query=dense_vector_from_sapbert, # Anlamsal benzerlik ve semptom eşleştirmesi
            using="dense"
            limit=50
        ),
        models.Prefetch(
            query=sparse_vector_from_bgem3, # Sentetik kod (E102, CAS No) eşleşmesi
            using="sparse"
            limit=50
        )
    ],
    query=models.FusionQuery(fusion=models.Fusion.RRF),
    query_filter=models.Filter(
        must=[
            models.FieldCondition(
                key="known_disease_triggers"
                match=models.MatchAny(any=["asthma", "salicylate_sensitivity"])
            )
        ],
        must_not=[
            models.FieldCondition(
                key="efsa_genotoxicity_flag"
                match=models.MatchValue(value=True)
            )
        ]
    ),
    limit=5
)
```

Bu Python kod bloğunda görüleceği üzere HNSW grafında gezinen arama algoritması, genotoksik maddeleri arama havuzundan tamamen çıkaran (must_not) ve hastanın astım/salisilat intoleransı ile doğrudan örtüşen hastalık tetikleyicilerine sahip kayıtları mecburi tutan (must) koşullarla iletir. Qdrant, filtreleri graf gezintisi (graph traversal) sırasında hesaba

kattığı için (in-graph filtering), sistem herhangi bir hız kaybı yaşamaz ve doğrudan riskli içeriği bularak önceliklendirir.

Adım 3: Regülatif Eşik Değerlerinin Dinamik İcrası (Threshold Execution)

Vektörel filtrelemenin tamamlanmasının ardından, tespit edilen kimyasalın klinik toksisite analizi başlar. JECFA tarafından Tartrazin için belirlenen spesifik NOAEL tabanlı Kabul Edilebilir Günlük Alım (ADI) dozu 7.5 mg/kg bw'dir.

Sistem, kullanıcının girdiği kişisel sağlık metrikleri (60 kg) üzerinden anlık bir matematiksel üst limit formülasyonu çalıştırır:

- Kullanıcı Ağırlığı: 60 kg
- Tüketilebilir Güvenli Üst Sınır: $60 \text{ kg} * 7.5 \text{ mg/kg} = 450 \text{ miligram/gün}$.

Ardından, FooDB veritabanındaki contents tablosu çağrılarak, taranan gıda kategorisindeki (örneğin "candy" veya "soft drinks") Tartrazin konsantrasyonu (orig_max, orig_content, orig_unit alanları) analiz edilir. Eğer ürün porsiyonu, bireyin 450 miligramlık kümülatif tolerans eşiğine yaklaşıyorsa, sistem sadece bir "alerjen uyarısı" vermekle kalmaz, aynı zamanda hücresel boyuttaki kümülatif riskleri (oksidatif stres kapasitesi artışı ve buna bağlı pankreatik doku yıpranması) açık bir rapor olarak sunar.

Aynı işlem, FooDB içerisinde tespit edilen ve tarım kalıntısı olan Dieldrin (FDB117974) veya Emamectin benzoate (FDB118714) gibi pestisit içerikleri için gerçekleştirildiğinde, EFSA'nın belirlediği ve Zenodo üzerinden güncellenen OpenFoodTox verileri ışığında çok daha katı bir must_not profili tetiklenecektir. Böylece, tüketici sağlığını tehdit eden ziraat artıkları algoritmik bir kalkanla durdurulmuş olur.

Biyomedikal Yapay Zekada Derinlemesine Çıkarımlar ve Gelecek Projeksiyonları

Yukarıda detaylandırılan veri, makine öğrenimi ve altyapı bloklarının birleşmesi, basit bir gıda analiz mobil uygulamasının ötesinde, halk sağlığı ve klinik toksikoloji açısından büyük sonuçlar doğuracak içgörüler (insights) yaratmaktadır.

Biyolojik veri kümeleri kendi içlerinde kapalı adalardır. FooDB molekül ağırlıklarını, JECFA ADI limitlerini, EFSA genotoksik sınırları, CTD ise patolojik hastalık bağlantılarını barındırır. SapBERT'in sağladığı UMLS tabanlı uzaysal hizalama sayesinde bu adalar birbirine bağlanarak daha önce literatürde keşfedilmemiş olan "dolaylı ve gizli biyokimyasal tetikleyiciler" ortaya çıkarılabilir.

Örneğin histamin intoleransı denildiğinde, bireylerin sadece fermente edilmiş içeceklerden veya bekletilmiş peynirlerden kaçınması gerektiği düşünülür. Oysa sistemin yapay zekası; tartrazin gibi bağımsız, endüstriyel boyaların mast hücreleri üzerinde kimyasal bir baskı oluşturduğunu, degranülasyon (histaminin hücre dışına sızması) etkisini dolaylı yoldan taklit ederek hastada ürtiker, dermatit ve astım gibi tam olarak histamin bazlı klinik bulgular oluşturduğunu algoritmik olarak birbirine bağlayabilir. Bu durum, reaktif diyet listelerinden proaktif fizyolojik korumaya geçiş anlamına gelir.

Buna ek olarak, hastaların klinik bulgularını her zaman kesin bilimsel terminolojilerle (örneğin; "gastrointestinal spazm" veya "dermatit") ifade edememesi sorunu da aşılmaktadır. Kullanıcı "Midemde yanma var, sürekli gaz çıkarıyorum ve cildim kaşınıyor" dediğinde, BGE-M3 ve

MedCPT entegrasyonu bu şikâyetleri FODMAP malabsorpsiyonu, histamin eksikliği veya salisilat intoleransı şemsiyesi altında toplayacak ve vektör grafında ilgili moleküllerin yolunu anında kesecektir.

Son olarak sistemin mimari felsefesi olan "Kuantize Edilmiş Graf Mimarisi", geleceğe dönük muazzam bir esneklik sunar. Avrupa Gıda Güvenliği Otoritesi'nin (EFSA) Nisan 2026 itibarıyla uygulamaya koyduğu OpenFoodTox 3.0 sürümündeki IUCLID 6 entegrasyonu, toksikokinetik verilerin sayısını binlerce katına çıkaracaktır. Qdrant'ın bellek tüketimini minimize eden optimizasyonları sayesinde, NutriScan gelecekte yalnızca sentetik katkı maddelerini değil, mikrobiyom analizi ile bireyin genetik şifresine kadar inen farmakogenomik haritalamaları da gerçek zamanlı bir şekilde veri tabanında işleyebilecek altyapıya sahip olacaktır. NutriScan, veriyi merkeze alan yapay zeka entegrasyonu sayesinde tıbbi doğrulanabilir, algoritmik olarak hatasız ve uçtan uca güvenli bir diyetetik asistan ekosistemine dönüşecektir.

Alıntılanan çalışmalar